

PRUEBA TÉCNICA

Ciencia de Datos

Analítica aplicada al aseguramiento de riesgos laborales

Campo	Detalle
Modalidad	Prueba individual
Plazo de entrega	Lunes 20 de julio a las 8:00 p.m., hora Colombia
Herramientas	R o Python más SQL, de libre elección
Puntaje	100 puntos
Clasificación	Documento de uso interno, no divulgar

Instrucciones de entrega

- La prueba debe resolverse en su totalidad antes del plazo de entrega.
- Entregue el desarrollo como un repositorio tipo git, con historia de commits, estructura de carpetas clara y un README de ejecución. El código debe ir en archivos ejecutables .py o su equivalente en R, no en notebooks, y ser reproducible: semilla fija, entorno documentado y rutas relativas.
- Incluya documentación técnica. Por cada modelo desarrollado entregue un documento con especificación, supuestos, validación, resultados y limitaciones.
- Declare de forma explícita los supuestos que adopte.
- Si utiliza herramientas de IA, entregue un documento aparte que indique en qué partes la usó, por qué la usó y qué tomó de ella.

Propósito de la prueba

Esta prueba evalúa la capacidad de conducir soluciones analíticas de extremo a extremo, desde la formulación del problema de negocio hasta la puesta en producción y su comunicación, en el contexto del aseguramiento de riesgos laborales. Los ejes centrales son la modelación económica y sectorial, la modelación para un reto de negocio, la medición causal de impacto y el diseño de un sistema de recomendación de servicios.

Contexto de negocio

La ARL asegura a empresas afiliadas frente a accidentes de trabajo y enfermedades laborales. Cobra primas según la clase de riesgo y la actividad económica de cada empresa, y ofrece programas y servicios de prevención. La Dirección de Analítica quiere entender los determinantes

económicos y sectoriales de la siniestralidad, proyectar el resultado técnico del portafolio, medir el impacto real de sus programas de prevención y recomendar a cada empresa los servicios con mayor probabilidad de ser adoptados y de reducir su riesgo. Para la prueba se entregan datos sintéticos que emulan estas fuentes. Su diccionario está en el Anexo A.

Estructura y puntaje

#	Sección	Puntos
1	Formulación, análisis exploratorio y fundamentos estadísticos	20
2	Modelación económica y sectorial del sector construcción	24
3	Modelación para reto de negocio	16
4	Medición de impacto, inferencia causal	17
5	Sistema de recomendación de servicios	11
6	De modelo a producto	8
7	Comunicación ejecutiva	4
	Total	100

| Sección 1. Formulación, análisis exploratorio y fundamentos estadísticos

Valor: 20 puntos

El negocio quiere anticipar qué empresas tendrán alta siniestralidad el próximo año para focalizar la prevención.

- 1.1** 4 puntos Enmarque el problema con la metodología CRISP-DM: explicité qué haría en las fases de comprensión del negocio y comprensión de los datos para este caso. Formule el problema analítico con unidad de análisis, variable objetivo y su definición operativa, esquema de validación y las métricas de éxito frente a una línea base, e identifique los riesgos de fuga de información presentes en estos datos.
- 1.2** 6 puntos Realice un análisis exploratorio completo: distribuciones univariadas de la frecuencia, la severidad, los costos y el tamaño de las empresas; asociaciones bivariadas de la siniestralidad con la clase de riesgo, el sector, el tamaño y la geografía; estructura temporal y estacionalidad; detección y tratamiento de valores atípicos; y correlación y colinealidad entre los predictores candidatos. Acompañe cada hallazgo con la visualización que lo sustenta y cierre con la síntesis de lo que condiciona el modelado.
- 1.3** 4 puntos A partir de las preguntas que surjan del análisis exploratorio, proponga y justifique al menos tres pruebas de hipótesis pertinentes para el negocio. Para cada una formule las hipótesis nula y alterna, elija la prueba adecuada verificando sus supuestos, corrija por comparaciones múltiples cuando corresponda, y distinga la significancia estadística de la relevancia práctica reportando el tamaño del efecto.
- 1.4** 3 puntos Diagnostique los datos faltantes de empresas.csv y siniestros.csv: cuantifíquelos, plantee una hipótesis sobre su mecanismo entre MCAR, MAR o MNAR, proponga y aplique una estrategia de imputación, y evalúe su efecto sobre el modelado frente a la alternativa de descartar registros.
- 1.5** 3 puntos Defina y justifique una línea base y establezca qué debería superar un modelo más complejo para justificar su costo.

Entregable: Repositorio con el código del análisis exploratorio, las pruebas de hipótesis, el diagnóstico e imputación de faltantes y la línea base, más su documentación técnica.

| Sección 2. Modelación económica y sectorial del sector construcción

Valor: 24 puntos

El sector construcción es uno de los de mayor accidentalidad y mayor sensibilidad al ciclo económico. La Dirección quiere anticipar la siniestralidad del sector a partir de su ciclo. El candidato debe combinar el panel sintético de `macro_sectorial.csv` con series públicas del DANE que él mismo debe identificar. Esta sección es el eje de la prueba y exige rigor econométrico, criterio de fuentes y un componente de soporte documental.

- 2.1** 5 puntos Caracterice el ciclo del sector construcción. Identifique y justifique al menos tres series públicas del DANE pertinentes para el ciclo del sector y construya con ellas un indicador líder. Discuta el rezago de publicación de cada fuente y su implicación para el análisis.
- 2.2** 8 puntos Modele la relación dinámica entre el ciclo del sector y la frecuencia de accidentes de trabajo del sector. Trate estacionariedad, rezagos y adelantos, y una posible relación de largo plazo entre actividad sectorial y siniestralidad. Justifique la especificación frente a alternativas y presente diagnósticos.
- 2.3** 5 puntos Produzca un nowcast de la frecuencia de accidentes de trabajo del trimestre en curso combinando la siniestralidad parcial observada con los indicadores líderes, considerando de forma explícita los distintos rezagos de publicación de las fuentes. Reporte la incertidumbre del nowcast.
- 2.4** 6 puntos El analista sectorial necesita apoyarse en un asistente que recupere información de un corpus documental y genere respuestas fundamentadas en él. Construya ese sistema de recuperación y generación aumentada, RAG, para que responda preguntas sobre un corpus de boletines del DANE y estudios del sector construcción. Debe recuperar los fragmentos pertinentes, fundamentar y citar cada respuesta en su fuente, y contar con una estrategia de evaluación de la calidad de las respuestas y de mitigación de alucinaciones. El asistente debe quedar integrado al flujo de la modelación anterior como herramienta de soporte a la investigación sectorial, no como pieza aislada.

Entregable: Repositorio con el código, el documento técnico del modelo, la construcción del indicador líder, los resultados de nowcasting con su incertidumbre, y el prototipo funcional del asistente RAG con su esquema de evaluación.

Sección 3. Modelación para reto de negocio

Valor: 16 puntos

El reto de negocio: la Dirección necesita anticipar el resultado técnico del portafolio y decidir dónde ajustar la suscripción y la tarifa. Usted debe modelar el costo esperado de siniestralidad y convertirlo en una recomendación.

- 3.1** 4 puntos Formule de forma explícita la pregunta de negocio que va a responder y las decisiones que su modelo debe soportar. Enuncie los supuestos que adopta y cómo los validará.
- 3.2** 7 puntos Modele la frecuencia y la severidad de los siniestros para estimar el costo esperado de siniestralidad por empresa y por clase de riesgo. Justifique las distribuciones elegidas y el tratamiento de la exposición, y valide el ajuste y la capacidad predictiva del modelo.
- 3.3** 3 puntos Proyecte el resultado técnico del portafolio para el próximo año: siniestralidad esperada frente a primas devengadas, estime el combined ratio en un escenario base y uno adverso, y cuantifique la incertidumbre de la proyección.
- 3.4** 2 puntos Documente el modelo de forma integral y traduzca el resultado en una recomendación accionable de negocio, explicitando los límites y los riesgos del modelo.

Entregable: Repositorio con el código, el documento técnico integral del modelo, la tabla de costo esperado por clase de riesgo y la distribución del resultado.

Sección 4. Medición de impacto, inferencia causal

Valor: 17 puntos

La ARL invirtió en un programa de prevención adoptado por cerca de 1500 empresas en distintos momentos entre 2019 y 2022, registrado en el archivo `programas_prevenccion.csv`. La adopción no fue aleatoria. Se quiere saber si el programa redujo la siniestralidad.

- 4.1** 7 puntos Proponga una estrategia de identificación creíble para estimar el efecto causal del programa sobre la siniestralidad. Represente el problema con un DAG, enuncie los supuestos de identificación y las principales amenazas a la validez.
- 4.2** 6 puntos Implemente su estrategia y estime el efecto del programa sobre las empresas tratadas, con errores estándar apropiados a la estructura de los datos. Incluya al menos una prueba de robustez.
- 4.3** 4 puntos Traduzca el efecto estimado a valor económico y sea explícito sobre qué tan causal es su conclusión y bajo qué supuestos podría romperse.

Entregable: Repositorio con el código, el documento técnico del modelo, el DAG y las pruebas de robustez.

| Sección 5. Sistema de recomendación de servicios

Valor: 11 puntos

El área quiere recomendar a cada empresa los servicios de prevención con mayor probabilidad de ser adoptados y de reducir su riesgo. Dispone del histórico de uso en `uso_servicios.csv`, de los atributos de los servicios en `catalogo_servicios.csv` y de los atributos de las empresas en `empresas.csv`, que en conjunto permiten construir el recomendador y resolver el arranque en frío de empresas sin histórico.

5.1 4 puntos Diseñe el recomendador: elija y justifique el enfoque más adecuado dadas las características del problema y de los datos disponibles.

5.2 4 puntos Implemente un prototipo funcional y evalúelo con una metodología de validación apropiada que incluya partición temporal. Reporte las métricas que considere pertinentes y discuta las limitaciones de la evaluación offline.

5.3 3 puntos Proponga cómo llevaría el sistema a producción y cómo mediría su impacto real de negocio.

Entregable: Repositorio con el código, el documento técnico, las métricas de evaluación y recomendaciones de ejemplo para tres empresas, incluyendo una sin histórico.

| Sección 6. De modelo a producto

Valor: 8 puntos

6.1 4 puntos Elija uno de los modelos anteriores y describa la arquitectura de puesta en producción de punta a punta: ingesta y preparación de datos, cómputo de features, entrenamiento, validación, empaquetado, despliegue como proceso batch o como servicio, y entrega de las predicciones al negocio. Asuma un stack en la nube corporativo sobre Azure y Databricks y justifique cada decisión.

6.2 4 puntos Defina la operación del modelo en el tiempo: monitoreo de desempeño y de deriva de datos y de concepto, mecanismo de detección y alertamiento, política y disparadores de reentrenamiento, y el gobierno del ciclo de vida mediante el versionamiento de datos, código y modelo, con trazabilidad y reproducibilidad.

Entregable: Documento o diagrama de la arquitectura de punta a punta más el plan de operación, monitoreo y reentrenamiento.

| Sección 7. Comunicación ejecutiva

Valor: 4 puntos

7.1 4 puntos Redacte un resumen ejecutivo de máximo una página, dirigido a la Junta Directiva, integrando los hallazgos de las Secciones 3 y 4. Debe incluir la recomendación accionable, el valor esperado, los supuestos clave y los riesgos, sin jerga técnica.

Entregable: Documento de una página.

Anexo A. Diccionario de datos

Se entregan seis archivos. Todos son sintéticos y no contienen información real de empresas ni de personas.

empresas.csv

Cerca de 5000 empresas afiliadas, una fila por empresa.

Campo	Tipo	Descripción
id_empresa	texto	Identificador único de la empresa
ciiu	texto	Código CIIU de la actividad económica, cuatro dígitos
sector	texto	Sección económica según CIIU
clase_riesgo	entero	Clase de riesgo de la ARL, de 1 a 5
n_trabajadores	entero	Número de trabajadores afiliados
ciudad	texto	Ciudad de la empresa
departamento	texto	Departamento de la empresa
antiguedad_meses	entero	Meses de afiliación a la ARL
prima_anual	numérico	Prima anual devengada en pesos
fecha_afiliacion	fecha	Fecha de inicio de la afiliación

siniestros.csv

Cerca de 40000 registros, una fila por siniestro.

Campo	Tipo	Descripción
id_siniestro	texto	Identificador único del siniestro
id_empresa	texto	Empresa a la que pertenece el siniestrado
fecha_ocurrencia	fecha	Fecha del evento
tipo	texto	Valor AT para accidente de trabajo y EL para enfermedad laboral
parte_cuerpo	texto	Segmento corporal afectado
dias_incapacidad	entero	Días de incapacidad generados
costo_asistencial	numérico	Costo médico asistencial en pesos
costo_prestacion_economica	numérico	Costo de prestaciones económicas en pesos
gravedad	texto	leve, grave o mortal

programas_preencion.csv

Cerca de 1500 empresas tratadas.

Campo	Tipo	Descripción
id_empresa	texto	Empresa que recibió el programa
programa	texto	Nombre del programa de prevención
fecha_inicio	fecha	Inicio de la intervención, escalado entre 2019 y 2022
horas_intervencion	numérico	Horas totales de intervención
cobertura_trabajadores	numérico	Proporción de trabajadores cubiertos por el programa

uso_servicios.csv

Cerca de 100000 registros de uso, base del recomendador.

Campo	Tipo	Descripción
id_empresa	texto	Empresa que usó el servicio
id_servicio	texto	Identificador del servicio, referencia a catalogo_servicios
fecha_uso	fecha	Fecha de uso
canal	texto	presencial, virtual o autogestión

catalogo_servicios.csv

Cerca de 40 servicios de prevención.

Campo	Tipo	Descripción
id_servicio	texto	Identificador del servicio
servicio	texto	Nombre del servicio
categoria	texto	Categoría del servicio
modalidad	texto	presencial, virtual o autogestión
dirigido_a	texto	Clase de riesgo o sector objetivo del servicio

macro_sectorial.csv

Panel sector por trimestre, de 2018Q1 a 2024Q4.

Campo	Tipo	Descripción
sector	texto	Sección económica, referencia a empresas.sector
anio	entero	Año del periodo
trimestre	entero	Trimestre del periodo
pib_sectorial_var	numérico	Variación porcentual del valor agregado sectorial
empleo_sectorial	numérico	Índice de empleo sectorial
ipp_sectorial	numérico	Índice de precios al productor del sector
tasa_informalidad	numérico	Tasa de informalidad sectorial en porcentaje